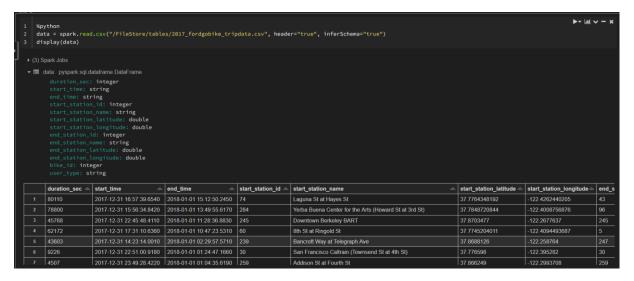
## Découverte et mise en oeuvre de Spark

Dans ce projet d'initialisation au Spark, j'ai commencé par créer un compte Databricks, puis j'ai fait l'ingestion de données.

Le dataset utilisé est sous forme d'un fichier CSV qui regroupe des données sur les déplacements à vélos, vous trouverez le fichier ici :

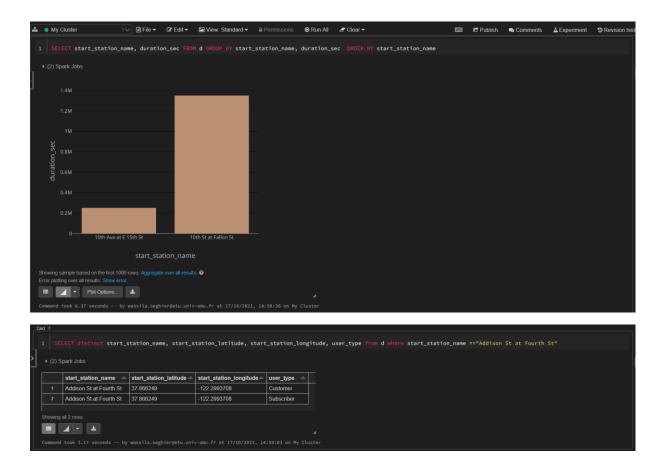
https://s3.amazonaws.com/baywheels-data/index.html

j'ai choisi par hasard le fichier 2017\_fordgobike\_tripdata.csv.



Après la phase d'importation des données, j'ai pu analyser celles-ci avec quelques requêtes SQL avec SparkSQL.

Par exemple la longitude des station et la latitude selon le nom de la station, j'ai compter le nombre de stations sur la base de données qui est de 272 et le type d'utilisateur client et abonné.



Puis j'ai attaqué la partie Machine learning, où j'ai construit un modèle pyspark pour détecter si l'utilisateur est un client ou un abonné.

Il a fallu d'abord équilibrer les données pour obtenir un bon modèle et cela en réduisant le nombre de Suscriber.



J'ai utilisé les Random Forest, decision trres et Gradient boosted trees comme algorithmes d'apprentissage (supervisé), j'ai divisé le corpus en un ensemble d'apprentissage et un ensemble de test, et cela après une phase de transformation des données pour cela j'ai utilisé un vecteur assembleur pour combiner les caractéristique que j'ai jugé utiles pour l'apprentissage.

Je n'ai gardé que les caractéristiques numériques, puis j'ai utilisé un string Indexer pour coder les étiquettes.

Ensuite j'ai entrainé mes modèles, le Random Forest a obtenu environ 72% d'accuracy, j'ai à la fin visualisé la matrice de confusion du modèle.

```
| Spython | Spyt
```

```
from pyspark.ml.evaluation import MulticlassClassificationEvaluator
    evaluator = MulticlassClassificationEvaluator(labelCol="labelIndex", predictionCol="prediction")
    accuracy = evaluator.evaluate(predictions)
print("Accuracy = %s" % (accuracy))
print("Test Error = %s" % (1.0 - accuracy))
 ▶ (2) Spark Jobs
|labelIndex|prediction|
        0.01
                  0.01
        1.0
                  0.0
        0.0
                  0.0
        1.0|
                  0.01
        0.0
                  0.0
        0.0
                  0.0
        0.0
                  0.0
        1.0
                  0.0
        0.0|
                  0.0
        0.0
                  0.0
only showing top 10 rows
Accuracy = 0.71908030458591
Test Error = 0.28091969541409
```

```
from pyspark.mllib.evaluation import MulticlassMetrics
from pyspark.sql.types import FloatType
import pyspark.sql.types import FloatType
preds_and_labels = predictions.select(['prediction','labelIndex']).withColumn('labelIndex', F.col('labelIndex').cast(FloatType())).orderBy('prediction')
preds_and_labels = preds_and_labels.select(['prediction','labelIndex'])
preds_and_labels = preds_and_labels.select(['prediction','labelIndex'])
print(metrics.confusionMatrix().toArray())

* (4) Spark Jobs

* Impreds_and_labels: pyspark.sql.dataframe DataFrame = [prediction: double, labelIndex: float]
[[27143. 6659.]
[12402. 20726.]]

Command took 18.22 seconds -- by wassila.seghier@etu.univ-amu.fr at 17/19/2021, 15:14:39 on My Cluster
```

Les arbres de décision ont obtenu environ 73% d'accuracy, j'ai à la fin visualisé la matrice de confusion du modèle.

```
from pyspark.ml.evaluation import MulticlassClassificationEvaluator
   evaluator = MulticlassClassificationEvaluator(labelCol="labelIndex", predictionCol="prediction")
   accuracy = evaluator.evaluate(predictions)
   print("Accuracy = %s" % (accuracy))
print("Test Error = %s" % (1.0 - accuracy))
 ▶ (2) Spark Jobs
|labelIndex|prediction|
       0.0
                  0.0
       1.0
                  0.0
                 0.0
       0.0
       1.0
                 0.0
       0.0
                 0.0
                  0.0
       0.0
        0.0
                  0.0
                  0.0
        0.0
                  0.0
        0.0
                  0.0
only showing top 10 rows
Accuracy = 0.7276193212548361
Test Error = 0.2723806787451639
```

Les GBT ont obtenu environ 75% d'accuracy (le meilleur modèle), j'ai à la fin visualisé la matrice de confusion du modèle.

```
%python
    predictions.select("labelIndex", "prediction").show(10)
    {\bf from\ pyspark.ml.evaluation\ import\ Multiclass Classification Evaluator}
    evaluator = MulticlassClassificationEvaluator(labelCol="labelIndex", predictionCol="prediction")
10 | accuracy = evaluator.evaluate(predictions)
print("Accuracy = %s" % (accuracy))
print("Test Error = %s" % (1.0 - accuracy))
 ▶ (2) Spark Jobs
|labelIndex|prediction|
                    0.0
        1.0
                    0.0
        0.0
                    0.01
         1.0|
                    0.0
         0.0
                    0.0
         0.0
                    0.0
only showing top 10 rows
Test Error = 0.25488821806443507
```

```
| Spython | From pyspark.mllib.evaluation import MulticlassMetrics | From pyspark.sql.types import FloatType | From pyspark.sql.types import pyspark.sql.functions as F | From pyspark.sql.types import pyspark.sq
```